

AI IN ACTION - Day 1

AI & LLM Foundation

Instructor: Mai Anh Nguyen (Blue)

Instructor



Mai Anh Nguyen (Blue)


Generalist Product Builder

- 2026 FPT Long Châu (PM · Healthcare Product)
- 2025 Thongtincuuho.org (Co-founder)
- 2025 FPT Software AI Center (PM · AI Agent)
- 2021 - 2025 Xantus (PM · On-chain Analytics, AI Agent)
- 2016 - 2021 DYNO, Kalapa (PM · OCR, eKYC, Credit Scoring)


[Linkedin](#) | [Facebook](#)

Lịch sử AI


Lịch sử AI 70 năm



1956: Dartmouth Workshop




1969: Perceptrons



Các hướng đi lần lượt **chạm trần**:

- **Hướng symbolic** (dạy máy bằng luật/quy tắc): bắt đầu đuối trước thế giới quá nhiều ngữ cảnh
- **Hướng Perceptron** (thay vì viết hết luật, mình có thể cho máy học từ ví dụ) cũng gặp vấn đề vì quá đơn giản


Mùa đông AI lần 1: 1974-1980



Mùa đông AI lần 1: Suy luận logic tổng quát không đủ sức xử lý thế giới thật.

Lúc bài toán còn nhỏ, mọi thứ trông khá thông minh. Nhưng khi bước vào thế giới thật, mỗi bước quyết định lại sinh ra quá nhiều nhánh → máy chìm trong không gian khả năng trước khi chạm được tới lời giải tốt

1980: Hệ chuyên gia (expert system)




Đặt lại vấn đề: “Nếu AI chỉ giải thật tốt một loại bài toán chuyên môn hẹp thì sao?”

→ Sự ra đời của **expert systems**

AI đổi chiến lược: thôi theo đuổi trí tuệ tổng quát và **tập trung giải thật tốt một miền hẹp bằng cách mã hóa tri thức chuyên gia thành luật**


Mùa đông AI lần 2




Expert systems từng tạo ra giá trị thật, nhưng càng mở rộng thì càng lộ trần: tri thức phải nhập bằng tay, luật càng nhiều càng khó cập nhật, và hệ thống khó đứng vững trước ngoại lệ mới.

→ **Mùa đông AI lần 2**

Sự ra đời của Deep Learning




Sau mùa đông lần hai, câu hỏi của cả ngành đổi hẳn: “Nếu không thể viết hết tri thức của thế giới vào máy, thì **có thể để máy tự học nó từ dữ liệu không?**”




Sự ra đời của Deep Learning



Machine Learning




Deep Learning



2012: AlexNet




ImageNet



AlexNet chiến thắng ở ImageNet Large Scale Visual Recognition Challenge

- ImageNet cho mô hình ăn một lượng dữ liệu chưa từng có ở thời điểm đó.
 - Kiến trúc sâu cho phép học dần từ cạnh, hình, bộ phận, rồi đến đối tượng.
 - GPU cung cấp đủ năng lực tính toán để quá trình huấn luyện trở nên khả thi.
- **Cả ngành bắt đầu tin rằng nếu dữ liệu và năng lực tính toán tiếp tục lớn lên, năng lực mô hình có thể còn đi xa hơn rất nhiều.**


2016: AlphaGo



AlphaGo và nước đi số 37


Ban đầu nó học từ khoảng 150.000 ván cờ của chuyên gia con người để có trực giác khởi đầu
→ Tạo ra nhiều bản sao của AlphaGo và để chúng **tự chơi với chính mình hàng triệu lần**
→ Hệ thống không chỉ học từ những gì con người đã biết, mà còn **tự mở rộng không gian chiến lược** bằng cách **khám phá những nước đi chưa từng được thử** trước đó.

2017: Transformer




Transformer là bước ngoặt vì nó cho mô hình hiểu ngôn ngữ theo cách linh hoạt hơn: **mỗi từ có thể nhìn sang những từ quan trọng khác** trong cả câu, thay vì chỉ đi tuần tự từng bước → trở thành nền móng kỹ thuật cho GPT, BERT và toàn bộ làn sóng LLM sau đó.

2022: ChatGPT



ChatGPT xuất hiện như một trải nghiệm đại chúng


Lần đầu tiên rất đông người dùng phổ thông có thể trực tiếp chạm vào một mô hình ngôn ngữ mạnh, thông qua một giao diện đơn giản đến mức ai cũng hiểu cách dùng



ChatGPT xuất hiện, chứng minh hiệu quả
→ trọng tâm của toàn ngành bắt đầu dồn về
cùng một trục

Trước khi ChatGPT bùng nổ, nghiên cứu mô hình ngôn ngữ phân thành rất nhiều nhánh


Behold, a wild pi creature,
foraging in its native _____




land	22%
forest	9%
country	5%
habitat	4%
forests	4%
soil	4%
territory	2%
woods	2%
lands	1%
waters	1%
woodland	1%
grass	1%
⋮	

Transformers, the tech behind LLMs - 3Blue1Brown


If you could see the underlying probability distributions a large language model uses when generating text, then **you**



If you could see the underlying probability distributions a large language model uses when generating text, then you **would**




If you could see the underlying probability distributions a large language model uses when generating text, then you would **essentially**




Attention in transformers, step-by-step - 3Blue1Brown

SWE-bench Verified: từ 33% (6/2024) lên ~81% (2/2026) — rồi chạm trần bão hòa




Nguồn: SWE-bench Verified = 500 issue GitHub thật, người đã lọc. Điểm CHÍNH THỨC từ công bố Anthropic (pass@1, không extended thinking) & swebench.com.
3.5 Sonnet 33.4% (6/24) · nâng cấp 49.0% (10/24) · 3.7 Sonnet 62.3% [scaffold 70.3%] (2/25) · Sonnet 4 72.7% (5/25) · Sonnet 4.5 77.2% (9/25) · Opus 4.5 80.9% (11/25).
Opus 4.6 (2/26): Anthropic ≈81% (81.4% khi có prompt modification, TB 25 lần chạy); tracker độc lập ~80.8% — frontier đã chứng quanh 80-81%.
Điểm xám: SWE-agent (2024) trên bản FULL 2.294 bài — thang đo khác, chỉ tham khảo. LƯU Ý: bảng tổng hợp bên thứ ba nêu 88-96% (tên model lạ, scaffold khác/chưa kiểm chứng) — KHÔNG dùng để trích.

DENSE (truyền thống)




GPT-2 · GPT-3 · Llama 1-3

MIXTURE OF EXPERTS



Mixtral · DeepSeek · Llama 4 · Qwen3

Minh họa khái niệm: token "nó" cần "chú ý" (attention) tới token nào để hiểu đúng nghĩa?




"Lan bỏ quyển sách vào túi vì nó quá dày" — muốn biết "nó" = quyển sách hay cái túi, mô hình so khớp "nó" với TẤT CẢ token trước đó, không chỉ token liền kề. Cung càng dày/đậm = trọng số attention càng cao (ở đây: hướng mạnh về "quyển"+"sách", không phải "túi").

★ Đây là biểu đồ KHÁI NIỆM (trọng số attention minh họa tay để giảng dạy), không phải trích xuất từ model thật — bản attention THẬT (trích từ model transformer) sẽ bổ sung ngay khi môi trường tính toán cài xong.

Ba trục làm model "giỏi hơn" — số tham số chỉ là MỘT trong ba, và không phải trục mạnh nhất

Nối lại slide "Why Now?" của Andrew Ng: slide đó chỉ về 1 biến (lượng dữ liệu). Ba biểu đồ dưới đây là 3 biến KHÁC mà slide gốc không thể hiện.



Nguồn: Trục 1 — Hoffmann et al. 2022, "Training Compute-Optimal Large Language Models" (Chinchilla, DeepMind): so sánh ở CÙNG ngân sách tính toán, Chinchilla 70B vượt Gopher 280B/GPT-3 175B/MT-NLG 530B.
Trục 2 — Ouyang et al. 2022, "Training language models to follow instructions with human feedback" (InstructGPT, arXiv:2203.02155): ở CÙNG kích thước 175B, model có RLHF được ưa thích 85±3% so với bản GPT-3 175B gốc (không RLHF).
Trục 3 — case study SWE-bench đã xác minh trong tài liệu nền Day 1 (Claude Opus 4.8: Verified 88.6% vendor-reported vs Pro 69.2%, cùng model, khác bộ đề/harness).